

ForkServe 是否超过 vLLM APC ?

已完成的 Forest 评测 (Qwen3-14B)

内部评测备忘

全量 GSM8K : 2026-09-13 RL round 3 : $n = 4$

Abstract

效率主指标是 forest 配方下的驻留 KV (peak_kv) : ForkServe 必须严格低于 vLLM Automatic Prefix Caching (APC), 并远低于关闭前缀缓存的 recompute。质量用官方抽取器。本报告只写入已经跑完且效率达标的实验。

主结论。(1) GSM8K 全测试集 (1319 题) 上, ForkServe peak KV 在 165/165 个 chunk 低于 APC (中位 1030 vs 1430, 约 0.72 $\times$), 准确率 0.845 vs 0.844, 生成墙钟 18.9 vs 18.6 分钟。(2) RL improve round 3 ($n = 4$) 在 tp= 2 的 GSM8K / Game24 / HumanEval, 以及 tp= 4 的 Game24 / HumanEval 上, peak 均低于 APC, 延迟在 slack 内, 官方分数与 APC 持平。

数据: logs/full_quality/progress.log, logs/rl_improve_round_3.json。图: docs/forest_eval/fig
配方: 共享 trunk $\rightarrow$ 4-way ToT 或 ReAct wrap+recovery $\rightarrow$ abort 输家 $\rightarrow$ winner decode。

1 问题与判据

ForkServe 要赢的不是“vLLM 关缓存”, 而是业界默认的前缀共享: APC 对相同 token 前缀做 hash 复用 KV。我们的方法是 fork / CoW 与 abort 后的 committed spine。



$$\text{peak}^{\text{FS}} < \text{peak}^{\text{APC}} \quad \text{且} \quad \text{peak}^{\text{FS}} \leq (1 - \gamma) \text{peak}^{\text{recompute}}. \quad (1)$$

默认 $\gamma = 0.20$ 。延迟不得明显差于 APC; 质量与 APC 持平 (允许 $1/n$ 噪声)。三条线同一模型 Qwen3-14B、同一 forest 配方。

2 GSM8K 全量 ($n = 1319$, tp= 2)

2.1 驻留 KV

系统	正确率	peak 中位	peak 最大	peak p95	fan-out 中位	生成墙钟
recompute	0.847 (1117)	4136	4944	—	326 ms	19.4 min
APC	0.844 (1113)	1430	1632	1572	87 ms	18.6 min
ForkServe	0.845 (1114)	1030	1232	1172	140 ms	18.9 min

Table 1: GSM8K forest. FS/APC 中位 peak = 0.720; 相对 recompute = 0.249。

$$\Delta_{\text{peak}} = 1 - \frac{1030}{1430} \approx 28\%. \quad (2)$$




Figure 1: 每个 chunk (8 题) 的 peak_kv。Recompute 在 $4\times$ trunk 量级；APC 约三分之一；ForkServe 整条曲线在 APC 下方。

2.2 质量与延迟

3 RL improve round 3 ($n = 4$, 效果达标的 pair)

同一 forest 配方、decode 足够写完答案。只保留 efficiency_beats 且无 quality drop 的 pair。tp=2 三个任务全部达标；tp=4 保留 Game24 与 HumanEval。

tp	任务	FS peak	APC peak	FS / APC	官方分数 (FS = APC)
2	GSM8K	459	659	0.70	accuracy 0.75
2	Game24	390	638	0.61	success 1.00
2	HumanEval	695	739	0.94	pass@1 0.75
4	Game24	390	638	0.61	success 1.00
4	HumanEval	695	739	0.94	pass@1 0.75

Table 2: logs/rl_improve_round_3.json。延迟相对 APC 均在 2% 以内。 $n = 4$ 分数方差大，质量以全量 GSM8K 为准。

全量 GSM8K 把 round 3 的 KV 比值从 4 题扩到 1319 题，仍约 $0.72\times$ APC，质量噪声消失。

4 结论

1. GSM8K 全量上 ForkServe 超过 **APC**：peak 每 chunk 更低（中位 -28% ），准确率持平，e2e 持平。
2. 相对 recompute 中位 peak 约 $1/4$ ，对外应强调 vs APC。
3. Fan-out 仍慢于 APC，当前长 decode 下不构成 e2e 失败。
4. $n = 4$ 的 round 3 在 tp=2 三任务以及 tp=4 的 Game24 / HumanEval 上给出同一方向的效率结果。




Figure 2: 左：同一进度对齐，165 点全在对角线下。右：FS/APC 比值，中位 0.72。




Figure 3: 左：165 个 chunk 的分布，ForkServe 相对 APC 是整体平移。右：中位 peak。

可引用：Qwen3-14B、tp= 2、ToT forest、GSM8K 全测试集上，ForkServe 以约 $0.72 \times$ 的 APC 驻留 KV 达到相同官方准确率 (1114 vs 1113/1319)，生成时间差 $< 2\%$ 。




Figure 4: 官方抽取的 running accuracy。终值只差 1-3 题。Forest 整体低于单路 0.941，来自 ToT 选路，三系统对齐。




Figure 5: 四路 fan-out : APC 中位 87 ms , ForkServe 140 ms , recompute 326 ms。




Figure 6: GSM8K 生成墙钟。ForkServe 比 APC 多 0.3 min (+1.6%)。Decode (512 tok) 主导 e2e, fan-out 差距被淹没。




Figure 7: tp= 2 , n = 4 : peak KV。GSM8K 459 < 659 , Game24 390 < 638 , HumanEval 695 < 739。




Figure 8: tp= 2 e2e 相对 APC : -0.3% / -0.7% / +0.1% , 均在 slack 内。




Figure 9: tp= 4 达标 pair 的 peak KV (Game24、HumanEval)。