

ForkServe

分支进 kernel 之前，决定这条 residual 要不要 prefill、要不要过 connector

一次 fan-out: trunk 长度 L , k 条 residual ℓ_i , 最后一条 committed spine

背景

Tree of Thoughts、ESC /
Speculative Rejection / DPTS、
APC 与 DistServe / Splitwise 各
自在哪一步付钱。

设计

Prefill 之前的 admission, 以及
connector 只搬 Keep。

结果

2026-10-01 prune ablation,
2026-09-29 三轮 ToT。
Qwen3-8B / 4B, A100-40GB。

一次 fan-out 的三笔账

Agent 和 Tree-of-Thoughts 的服务单位是一次分支：共享一条 trunk，分叉出 k 条短 residual，最后只提交一条 spine。传统栈对这次分支收三笔钱。

Work, GPU prefill

第一次 expand 时 block 还没进 radix index。APC 和 hash prefill 把 trunk 克隆 k 份。

$$W = kL + \sum_i \ell_i$$

Xfer, connector

DistServe / Splitwise 把 prefiller 算出的每一页传给 decoder。被丢掉的 residual 如果已经 insert，也在这条链路上。

Decode-to-cut

ESC、Speculative Rejection、DPTS 的分数来自已经 resident 的 token。Prefill 和一段 decode 发生在丢弃之前。

后面的设计对着后两笔账

Admission 在 kernel 之前丢掉不该留的 residual。Connector 只搬 Keep 的 miss。Decode-time pruning 剪不到这两笔。

Yao, Yu, Zhao, Shafran, Griffiths, Cao, Narasimhan. *Tree of Thoughts: Deliberate Problem Solving with Large Language Models*. NeurIPS 2023.
Kwon, Li, Zhuang, Sheng, Zheng, Yu, Gonzalez, Zhang, Stoica. *Efficient Memory Management for Large Language Model Serving with PagedAttention*. SOSP 2023.
Zhong, Liu, Chen, Hu, Zhu, Liu, Jin, Zhang. *DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving*. OSDI 2024.

Patel, Choukse, Zhang, Shah, Goiri, Maleki, Bianchini. *Splitwise: Efficient Generative LLM Inference Using Phase Splitting*. ISCA 2024.

ESC: 窗口里的样本一致才停




Figure 1: Full process of ESC compared with original SC. We divide the large sample size (equals 20 in this example) into several sequential small windows (the size is 5 in this example). Stop sampling when answers within a window are all the same, i.e., the entropy score of predicted answer distribution is zero. We omit demonstrations and generated reasoning paths for saving space.

计划抽 L 个完整样本（图中 $L=20$ ）。切成顺序窗口，窗口大小 $w=5$ 。一个窗口里答案的熵为 0，也就是五个答案相同，才停止后面的采样，再对已经抽到的样本投票。分数读的是已经生成完的答案。窗口关不上时，每个样本都要 prefill，并 decode 到预算。图：原文 Figure 1。Li, Yuan, Feng, Pan, Wang, Sun, Wang, Li. *Escape Sky-High Cost: Early-Stopping Self-Consistency for Multi-Step Reasoning*. ICLR 2024.

Speculative Rejection: 部分奖励到了 τ 再砍分位




Figure 1: **Left:** An illustration of our method. Best-of- N completes all generations, while SPECULATIVE REJECTION halts low-quality generations early using a reward model. **Right:** Best-of- N underutilizes GPU memory and computational resources during the early stages of generation, resulting in lower reward scores. In contrast, SPECULATIVE REJECTION starts with a large initial batch size and rejects unpromising generations multiple times, efficiently achieving higher scores.

Best-of- N 把 N 条生成全部跑完，再用 reward model 挑最高分。Speculative Rejection 先用很大的 batch 开跑，在 partial-reward horizon τ （论文里 $\tau=256$ ）用 reward model 给半成品打分，停掉较低分位 α ，把省下的显存让给还活着的候选。停掉之前，每条候选的 prefill 和前 τ 个 token 已经付过。Memory-limit 触发器在小 k 上不会响。图：原文 Figure 1。Sun, Haider, Zhang, Yang, Qiu, Yin, Wang, Bartlett, Zanette. *Fast Best-of-N Decoding via Speculative Rejection*. NeurIPS 2024.

DPTS: 每个节点先跑 mini-step, 再 early-stop




Figure 4: Overview of the proposed DPTS framework. The right part demonstrates the Parallelism Streamline, while the left and middle illustrate the proposed Search and Transition Mechanism.

左：Parallelism Streamline 把树上不同长度的路径 pad 齐，一起过 LLM，并管理 past KV。右：Search and Transition。Exploit 继承高置信父节点；Explore 按 $1-p$ 展开。孩子先生成固定 mini-step，置信度低于 θ_{es} 就 early-stop，高于 θ_{ds} 才继续 deep seek。剪枝读的是已经生成的 mini-step。我们复现时这一步是 100 token。图：原文 Figure 4。Ding, Jiang, Liu, Jing, Guo, Wang, Zhang, Wang, Liu, Du, Liu, Tao.

Dynamic Parallel Tree Search for Efficient LLM Reasoning. ACL 2025.

三篇都是 prefill 之后才剪

Qwen3-8B, GSM8K, $n=16$, $D=512$, $tp=1$, 四张 A100-40GB。 $k=16$ 时三个 host 单独跑, computed prefill 都是 5008。

方法	丢掉之前	prefill	decode	e2e	any
ESC	窗口内完整样本一致	5008	131072	17.05 s	16/16
Spec. Rejection	生成到 τ , 再砍较低一半	5008	98304	13.14 s	16/16
DPTS	每个节点 100-token mini-step	5008	78336	11.86 s	16/16
$+\tau_{pre}=0.15$	loop 在 kernel 前	3848	见下页	见下页	16/16

DPTS 最早, 仍然

把 16 条 residual 全部 prefill。代价模型里它在被丢掉的孩子上还要 decode 2000 token, 切点在 78.7 ms。ESC 的窗口在这个 fan-out 上关不上, 切点在 276 ms。 Li, Yuan, Feng, Pan, Wang, Sun, Wang, Li. *Escape Sky-High Cost: Early-Stopping Self-Consistency for Multi-Step Reasoning*. ICLR 2024. Sun, Haider, Zhang, Yang, Qiu, Yin, Wang, Bartlett, Zanette. *Fast Best-of-N Decoding via Speculative Rejection*. NeurIPS 2024. Ding, Jiang, Liu, Jing, Guo, Wang, Zhang, Wang, Liu, Du, Liu, Tao. *Dynamic Parallel Tree Search for Efficient LLM Reasoning*. ACL 2025. GPU: logs/prune_ablation_thresh/all.json, 2026-10-01, policy = base。


Pruning 在 insert 之前，connector 只搬 Keep

Decode-time pruning + P/D




$W = X = kL + \sum_i \ell_i$ 。被丢掉的孩子已经进过 kernel，也已经过了 connector。

这里：admission，然后只搬 Keep



Index 0 永远在 Keep。 $s'_i \geq \tau$ 才从 t_0 续到预算 D 。 $X = \sum_{i \in \text{Keep}} W_i$ 。

五个动作：同一条规则决定 W 和 X



论文图：一条 radix 上的五个动作。绿页在 H ，橙页是 prefill，灰页是 withheld。




两个旋钮。 τ_{pre} 决定 prefill 前丢掉谁。 t_0 决定低分但不是 loop 的 residual 先探多长。

最好的点	设置	效果
默认, 每个 k 都守住精度	$\tau_{\text{pre}}=0.15$	$k=4/8/16: 15/16, 16/16, 16/16$ 。Prefill -23% ($k=16: 5008 \rightarrow 3848$)。ESC $17.05 \rightarrow 14.13\text{ s}$ 。
宽树下最快、精度不掉	$\tau_{\text{pre}}=0.45, k=16$	仍是 $16/16$ 。ESC 10.92 s , prefill 2768 (-45%)。SR 10.80 s , DPTS 10.90 s 。
窄树上不用 0.45	同一阈值, $k=4, 8$	ESC 掉到 $14/16$ 。0.45 会连 illegal text 一起丢。所以默认留在 0.15。
MATH-500, 探到能恢复精度	$t_0=128, k=16$	any-finished $20/32$, 和 full fan-out 一样。 $104.1 \rightarrow 72.2\text{ s}$ 。Decode token $524288 \rightarrow 393216$ 。
$k=8$ 上更短的 probe 更好	$t_0=64, k=8$	$16/32, 42.0\text{ s}$ 。Full fan-out 是 $15/32, 52.5\text{ s}$ 。

τ_{pre} : prune_ablation_thresh。 t_0 : prune_ablation_grow 与论文 tab:grow。一刀切丢掉全部 $s < \tau$ 在 $k=16$ 只有 $13/32$ 。

同一个 τ_{pre} 插在三个 host 前面

GSM8K, Qwen3-8B, $n=16$, $D=512$



Host alone

$\tau_{\text{pre}}=0.15$


$\tau_{\text{pre}}=0.45$

(c) gold = host, orange = $+\tau_{\text{pre}}=0.15$

论文图。GSM8K, Qwen3-8B, $n=16$, $D=512$ 。来源 `logs/prune_ablation_thresh/all.json`。

为什么不能把低分全部挡在 prefill 前

MATH-500, Qwen3-8B, $n=32$, $D=1024$, $\tau=0.45$



论文图。Grow 行与 2026-10-01 的 shard JSON 一致。Full / 一刀切来自同一次实验的 tab:grow。

P/D 分离之后，pruning 少搬了什么

DistServe 和 Splitwise 的 connector 搬运 prefiller 已经算出的页。Admission 把 Keep 定在 insert 之前。Zhong, Liu, Chen, Hu, Zhu, Liu, Jin, Zhang. *DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving*. OSDI 2024.

Patel, Choukse, Zhang, Shah, Goiri, Maleki, Bianchini. *Splitwise: Efficient Generative LLM Inference Using Phase Splitting*. ISCA 2024.


Kwon, Li, Zhuang, Sheng, Zheng, Yu, Gonzalez, Zhang, Stoica. *Efficient Memory Management for Large Language Model*

	APC	P/D	ForkServe	ForkServe+
<i>Serving with PagedAttention</i> . SOSP 2023.				
Prefill tokens W	11520	11520	3840	2592 相
Connector tokens X	0	11520	0	32
Fan-out	139 ms	162 ms	47 ms	31.4 ms


对 APC, prefill token -77% 。相对 P/D, connector 从 11520 token 降到 32。GPU 上的对应物是三轮 ToT: ForkServe+ 的 `transfer_tokens` 是赢家的 miss (Qwen3-8B GSM8K 为 1402), 192 条 residual 里 144 条没有 prefill。前三行是控制面代价模型, 不是 GPU wall clock。10 sessions, $k=4$, $L=256$, $\ell=32$ 。论文 tab:app。

KV 占用：剪掉的 residual 不再堆在 live set 里

(a) Three systems, GSM8K $n=1319$ (one batch of eight)




(b) Two workloads, $n=40$ (GSM8K vs. Game24)




Time is the expand $\rightarrow$ abort $\rightarrow$ decode phase. Peaks are measured.

论文图。Qwen3-14B GSM8K 的 peak 是 4136 / 1430 / 1030。ForkServe+ 与 ForkServe 共享 spine，更早丢掉 residual 的 W 。



论文图。logs/tot_mt, 2026-09-29, $n=16$, $tp=2$, one problem per generate。8B GSM8K 端到端 $2.48 \rightarrow 1.91$ s; 4B GSM8K token 几乎不变, 端到端 $1.66 \rightarrow 1.63$ s。

Expand 是 APC 的 7.9–10.6 倍




Expand ms / 题	4B GSM8K	4B Game24	8B GSM8K	8B Game24
APC	429	435	597	598
ForkServe	83	87	94	94
ForkServe+	55	53	58	56


论文图与 fanout_ms/16。ForkServe 的端到

端仍贴着 APC，因为两步 32-token decode 记在 decode 计时里。

六个模型上的 peak KV




论文图。 $n=40$, $tp=2$ 。 GSM8K 上 spine / APC 是 $0.72-0.75\times$ ， Game24 上是 $0.57-0.61\times$ 。





论文图。 $n=80$, $tp=2$, $D=512$ 。 GSM8K 端到端 36.0 $\rightarrow$ 28.2s。 Peak KV: 1582 $\rightarrow$ 1182。

每题 decode 长度



论文图。 $n=40$, $tp=2$, bin 宽 64。端到端拉开的运行，是发出的 token 也变少的那些。

同一块显存上的并发



论文图。1s P99 TTFT: APC 在 448 QPS 越过, ForkServe 在 512 QPS 仍是 0.81s。

最好的安全点

$\tau_{\text{pre}}=0.15$: $k=8, 16$ 为 16/16, $k=4$ 为 15/16。
宽树上 $\tau_{\text{pre}}=0.45$ 同样 16/16, ESC 10.92s。
MATH-500 上 $t_0=128$ 回到 20/32。

只留 1 条会伤精度

`prune_ablation_wide` 里没有 score 模式的 app, 在 $k=16$ 只 admit 1 条。ESC 掉到 11/16, SR 掉到 9/16。同一阈值的 score 模式 admit 8 条, 保持 16/16。

1. ESC 等一个窗口的完整样本，Speculative Rejection 等到 τ ，DPTS 等到 mini-step。三篇的分数都来自已经 resident 的 token，所以 $k=16$ 时 computed prefill 都是 5008。P/D 接着把这些页全部传走。
2. 这里的 admission 在 kernel 之前处理重复 loop，其他低分只给 t_0 的 probe。Connector 只搬 Keep 的 miss。五个动作同时决定 W 和 X 。
3. 最好的安全点是 $\tau_{\text{pre}}=0.15$ 。宽树上 $\tau_{\text{pre}}=0.45$ 仍是 16/16，ESC 从 17.05 s 降到 10.92 s。MATH-500 上 $t_0=128$ 把 20/32 的精度留住，时间从 104.1 s 降到 72.2 s。